R - inferenční statistika

Lubor Homolka

12. května 2014

Obsah školení

Teoretická část:

- Domácí cvičení
- Replikace a pravděpodobnost
- Schéma testování hypotéz: vědecká vs. statistická
- Chyby v interpretaci výsledků
- Meta-analýza

Praktická část:

- proporční test prop.test
- t-test a ANOVA
- meta-analýza

Domácí cvičení - dotazy

https://github.com/luboRprojects

 $R\text{-skoleni2} \quad \to \quad \text{skript: plyr_ukazka.R}$

Frekvencionalistická statistika

$$Pravděpodobnost = \frac{Příznivá pozorování}{V šecha pozorování}$$

Chyba
$$\alpha = P(zamítáme H_0|H_0 = pravdivá)$$

$$\alpha = \frac{\text{Počet článků, které zamítnou}}{\text{Všechny články}}$$

Chyba
$$\beta = P$$
 (nezamítáme $H_0|H_0$ = nepravdivá)

$$\beta = \frac{\text{Počet článků, které nezamítnou}}{\text{Všechny články}}$$



Hypotézy

- Popperova falzifikace,
- Epistemologický boj: Neymar-Pearson a Fisher
- Vědecká hypotéza: Organizace se správně implementovaným BSC, dosahují vyšší finanční výkonnosti (měřeno ROE).
- Nulová hypotéza: Efekt implementace BSC na ROE neexistuje: $H_0: \beta = 0$
- Alternativní hypotéza: Efekt implementace BSC na ROE je kladný: $H_1: \beta > 0$

- nezveřejnění p-val > 0.05.
- statistická významnost vs. věcná významnost
- kontrola splnění předpokladů alternativní přístupy k asymptotickému odhadu (Monte Carlo)
- nepřesná interpretace intervalů spolehlivosti

Meta-analýza: Analýza síly testu

- Jak ambiciózní je naše analýza?
- Jaké výsledky můžeme očekávat?
- Jak velký má být vzorek?

Analyzovaný problém souvisí s:

- skutečným rozdílem mezi charakteristikami (effect size)
- neurčitost v chováním proměnných (variance)
- váha našeho důkazu (observations)
- požadovaná míra chybovosti (α , 1β).

Domníváme se, že průměrná hodnota ROE firem, které správně implementují BSC je o 3 % vyšší než u ostatních firem. Očekáváte, že rozptyl ROE je 36%. Protože nevíte, zda opravdu BSC přináší pozitivní efekt, musíte specifikovat toleranci k oběma chybám. Je nepřijatelné, abyste potvrdili, že vliv existuje v případě, kdy neexistuje ($\alpha=0.05$). Naopak, až tolik nevadí, když nenajdete důkaz pro existenci efektu, pokud existuje ($\beta=0.2$), neboli síla testu je 0.8.

Jaký je minimální počet respondentů pro náš výzkum?

Test rozdílu středních hodnot pro dvě úrovně je studentův t-test (t.test).

effect size pro t-test je stanoven jako:

$$d = \frac{\mu_1 - \mu_2}{\sigma}$$

Existuje velmi mnoho možností úprav, jako rozdílné velikosti souborů, rozdílné rozptyly apod.

Výsledky:

Two-sample t test power calculation

n = 111.9686

d = 0.3333333

sig.level = 0.05

power = 0.8

alternative = greater

NOTE: n is number in *each* group

Náš vzorek by musel být více než 220 firem, abychom dokázali detekovat rozdíl 2 %!

Analýza síly testu – Váš úkol

Neprovedli jste power analýzu a nyní Vám nic nevychází! Nasbírali jste totiž jen 80 firem v každé skupině (BSC, non-BSC). Jak velký by musel být skutečný efekt na ROE (rozdíl mezi $\mu_{\rm BSC}$ a $\mu_{\rm non-BSC}$), abyste tento rozdíl byli schopni nalézt?

github.com/luboRprojects/r_skoleni2/power_analysis.R

Analýza síly testu – Řešení

```
> pwr.t.test(n = 80, sig.level = 0.05, power = 0.8,
    type = c("two.sample"), alternative="greater" )

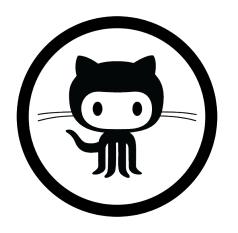
Two-sample t test power calculation

    n = 80
    d = 0.3948399

sig.level = 0.05
    power = 0.8
alternative = greater
```

Efekt by musel být minimálně 2.369 %, abychom ho dokázali detekovat.

 $0.3948399 = \frac{\text{efekt}}{0.06}$



github.com/luboRprojects/r_skoleni2/elementary_methods.R

Proporční test

Testuje hodnotu nebo shodu podílů π . Nulová hypotéza tvrdí, že neexistuje rozdíl $H_0:\pi_1=\pi_2$

Zeptali jsme se 100 Čechů a 100 Slováků na preferenci daného výrobku.

- Možné odpovědi: líbí/nelíbí
- 75% Čechů se líbí, Slovákům pouze 70 %
- Je možné tvrdit, že existují různé preference?
- > prop.test(x=c(75, 70), n=c(100, 100))

Jak by se situace změnila, kdyby náš vzorek byl $10\times$ větší? (a proporce se zachovaly)

Analýza kontingenční tabulky

Zjišťujeme, zda struktura kontingenční tabulky získané z našich dat odpovídá té, kterou bychom očekávali nastala, kdyby neexistoval vztah mezi proměnnými.

$$CH = \sum \sum \frac{\left(n_{ij} - n_{ij}^*\right)^2}{n_{ij}^*}$$

- V případě splnění podmínek má testové kritérium $\it CH$ rozdělení χ^2
- Porušení podmínek (min. počet pozorování v buňce 5) neumožňuje srovnání CH s χ^2 .
- V případě porušení podmínek buď fisher.test, nebo parametr simulate.p.value=TRUE ve funkci chisq.test.

Kontingenční tabulka - příklad

```
Je prokazatelné, že se BSC firmy více hlásí k CSR?
> data.chi <- as.data.frame(matrix(c(30, 90, 60, 40),</pre>
byrow=TRUE, ncol=2))
> data chi
        CSR-ne CSR-ano
            30
BSC
                     90
non-BSC 60
                     40
> chisq.test(data.chi)
Pearson's Chi-squared test with Yates'
   continuity correction
data: data.chi
X-squared = 26.2121, df = 1, p-value = 3.059e-07
```

Korelační analýza

Míra intenzity lineárního vztahu. Nulová hypotéza tvrdí, že vztah neexistuje, neboli H_0 : $\rho=0$.

- funkce cor vytváří korelační matici, ale netestuje významnost
- funkce cor.test provádí párové testy a přináší další možnosti, jako je např. volba typu korelačního koeficientu (Pearson, Spearman).

```
cor(data.in[ ,c("Fresh", "Milk", "Grocery")])
cor.test(data.in$Fresh, data.in$Milk)
```

Regresní analýza

Analyzuje kauzální vztah mezi vysvětlovanou proměnnou a vysvětlujícími proměnnými.

Testujeme významnost jak celkového modelu, tak jednotlivých koeficientů.

- hodnoty testů získáme ze summary(objekt)
- celkový F-test je model lepší než průměr? $H_0: \beta_1 = \ldots = \beta_k = 0$
- přispívá koeficient β k vysvětlení? $H_0: \beta_I = 0$

Prezentace a její obsah je samozřejmě reproducible!



https://github.com/luboRprojects/r_skoleni2/